

PROBLÈME 3

MICHAL URDANIVIA, UNIVERSITÉ DE GRENOBLE ALPES, FACULTÉ D'ÉCONOMIE, GAEL

Courriel: michal.wong-urdanivia@univ-grenoble-alpes.fr

11 OCTOBRE 2017

1. ESPÉRANCE CONDITIONNELLE ET MEILLEURE PRÉDICTION

Supposons que l'on cherche à prédire une variable $Y \in \mathbb{R}$ par un ensemble de variables représentées par le vecteur $X \in \mathbb{R}^K$. Cette prédiction est une fonction $g(x)$ pour les valeurs de $X = x$. L'erreur de prédiction est $Y - g(x)$ et une mesure de l'ampleur de cette erreur est l'espérance de son carré,

$$\mathbb{E}[(Y - g(x))^2 | X = x]$$

qui est l'**erreur quadratique moyenne**.

(1) Montrer que,

$$\mathbb{E}[(Y - g(x))^2 | X = x] = \mathbb{V}(Y|x) + (g(x) - \mathbb{E}(Y|x))^2$$

où $\mathbb{E}(Y|x) = \mathbb{E}(Y|X = x)$, $\mathbb{V}(Y|x) = \mathbb{V}(Y|X = x)$.

(2) En déduire que l'erreur quadratique moyenne est minimisée pour $g(x) = \mathbb{E}(Y|x)$.

2. LINÉARITÉ DE L'ESPÉRANCE CONDITIONNELLE

Supposons que $X = (1, W)^\top$ et que,

$$\mathbb{E}(Y|X) = \beta_0 + \beta_1 W$$

avec

$$(\beta_0, \beta_1) = \arg \min_{b_0, b_1} \mathbb{E}((Y - b_0 - b_1 W)^2)$$

(1) Donnez les conditions du premier ordre qui définissent β_0 et β_1 .

(2) Montrez que $\beta_0 = \mathbb{E}(Y) - \beta_1 \mathbb{E}(X)$ et $\beta_1 = \frac{\mathbb{C}(X, Y)}{\mathbb{V}(X)}$.

3. RÉGRESSION LINÉAIRE SIMPLE

Exercice 1. Considérons le modèle défini par,

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i, \quad i = 1, \dots, n$$

pour un échantillon i.i.d., et où $\mathbb{E}[\epsilon_i] = 0$, $\mathbb{V}(\epsilon_i) = \sigma^2$. Soit $\hat{\beta}_0$, et $\hat{\beta}_1$ les estimateurs des moindres carrés de β_0 et β_1 .

(1) Calculez $\mathbb{V}(\hat{\beta}_0 | X_i)$.

- (2) On calcule les résidus $\hat{\epsilon}_i = Y_i - \hat{Y}_i$, où $\hat{Y}_i = (\hat{\beta}_0 + \hat{\beta}_1 X_i)$ sont les valeurs ajustées. Montrez que $\sum_{i=1}^N \hat{\epsilon}_i = 0$.
- (3) Montrez que $\sum_{i=1}^N \hat{Y}_i \hat{\epsilon}_i = 0$. Quelle est l'interprétation de ce résultat.
- (4) Supposons que vous calculiez une régression des Y_i sur les résidus ϵ_i (autrement dit, que vous estimiez $Y_i = \alpha_0 + \alpha_1 \epsilon_i + v_i$, v_i étant l'erreur du modèle). Quels seraient les paramètres estimés par MCO de α_0 , et α_1 ?

Exercice 2. Considérons le modèle,

$$Y_i = \beta_1 X_i + \epsilon_i$$

- (1) Calculez l'estimateur des MCO de β_1 , noté $\hat{\beta}_1$.
- (2) Montrez que $\hat{\beta}_1$ est sans biais (autrement dit, que $\mathbb{E}[\hat{\beta}_1] = \beta_1$).
- (3) Supposons que le vrai modèle soit en fait $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$. Montrez que $\hat{\beta}_1$ calculé dans la première question est biaisé, et donnez une expression de son biais.

4. EXERCICE DE SIMULATION

- (1) Générez $n = 100$ observations de la façon suivante. D'abord générez une variable $X_i \sim \mathcal{U}(0, 1)$ et une autre variable $\epsilon_i \sim \mathcal{N}(0, 1)$. Pour $\beta_0 = 5$ et $\beta_1 = 3$ calculez,

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i, \quad i = 1, \dots, n$$

Représentez alors graphiquement les points $\{(Y_1, X_1), \dots, (Y_n, X_n)\}$. Calculez les estimateurs de MCO et ajoutez sur le même graphique la droite $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$.

- (2) Répétez l'expérience du point précédent 1000 fois. Pour chaque répétition vous aurez un estimateur $\hat{\beta}_1^{(t)}$, pour $t = 1, \dots, 1000$. Calculez la moyenne de la suite des valeurs ainsi obtenues. A quelle valeur de la moyenne devriez vous vous attendre ? Représentez un histogramme de cette suite.
- (3) Répétez le point précédent mais avec ϵ_i suivant une loi de Cauchy. Cette distribution ressemble à la distribution normale mais avec des queues très épaisses. Quels modifications constatez vous au niveau de l'histogramme ?
- (4) Étudions à présent ce qu'il arrive quand les X_i sont observés avec des erreurs. Pour cela, générez $n = 100$ comme suit :

$$X_i \sim \mathcal{U}(0, 1)$$

$$W_i = X_i + \delta_i$$

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

où $\beta_0 = 5$, $\beta_1 = 3$, $\epsilon_i \sim \mathcal{N}(0, 1)$, et $\delta_i \sim \mathcal{N}(0, 2)$. Supposons que nous n'observons que $(Y_1, W_1), \dots, (Y_n, W_n)$. Représentez graphiquement ces points. Calculez les estimateurs de MCO dans la régression des Y_i sur W_i , et représentez la droite $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$. Répétez cette expérience 1000 fois et calculez la moyenne de $\hat{\beta}_1$ sur les 1000 valeurs obtenues. Représentez aussi l'histogramme pour la suite des valeurs obtenues. D'après cet exercice quel est l'effet des erreurs de mesure sur les X_i .